电商客户流失预测与
价值分层分析报告

基于 SQL 数据洞察与机器学习的客户流失预警体系

2026 年 11 月

目 录

一、项目背景与目标 1

二、数据来源与技术栈 1

三、SQL 数据分析：价值分层流失洞察 2

3.1 数据预处理与类别映射 2

3.2 客户价值类别流失净值占比 3

3.3 客户细分类别流失净值占比 3

3.4 核心发现：高价值客户流失损失占比 96% 3

四、机器学习建模：流失概率预测 4

4.1 数据准备与特征工程 4

4.2 特征相关性分析与降维 4

4.3 样本不平衡与双重加权机制 5

4.4 四模型基线对比 6

4.5 LightGBM 深度交叉验证 7

4.6 测试集最终预测 7

五、模型可解释性分析 8

5.1 特征重要性排名 8

5.2 SHAP 解释 8

六、业务落地：风险分层与挽留策略 10

七、总结 11

执行摘要

高价值流失 CLV 占比	最优模型 AUC	流失类召回率	整体流失率
96.01%	0.7174	68%	约 40%

本报告针对某电商平台约 40% 的客户流失问题，通过 SQL 数据洞察发现"高价值客户流失损失占比高达 96.01%"这一关键结论，并据此构建了融合业务价值权重的机器学习流失预测模型。最终 LightGBM 模型 AUC 达 0.7174、流失类召回率达 68%，配合 SHAP 可解释性分析，为业务端输出高危客户预警名单与精细化挽留策略，实现降本增效。

一、项目背景与目标

某电商平台近期客户流失率高达 **40%**，给平台的持续经营带来了严峻挑战。传统的挽留策略普遍采用"一刀切"的群发优惠券方式，一方面营销成本居高不下，另一方面由于优惠资源未能精准投放到真正值得挽留的客户身上，实际挽留效果十分有限。

本项目的核心目标是：**通过 SQL + Python 机器学习技术，建立一套精准的客户流失预警体系，实现降本增效。**具体而言，项目需要回答三个关键问题：

谁最值得挽留？通过 SQL 数据洞察识别不同价值层级客户的流失损失，明确挽留优先级；**谁会流失？**通过机器学习模型预测每一位客户的流失概率，提前锁定高风险客户；**为什么流失？**通过 SHAP 可解释性分析，找到驱动流失的核心因素，为精细化运营策略提供依据。

二、数据来源与技术栈

本项目数据来源于 Kaggle 开源电子商务数据集，原始数据共包含 **50,000**

条客户记录、35 个字段，涵盖客户基本属性、消费行为、服务互动、营销触达及流失状态等维度。

整个分析流程分为"数据洞察"与"机器学习建模"两个阶段，采用如下技术栈：

阶段	技术栈
数据提取与清洗	MySQL（窗口函数、CTE 公共表表达式、表结构转换）
探索性数据分析（EDA）	Python（Pandas、Seaborn、Matplotlib）
机器学习建模	LightGBM、XGBoost、RandomForest、DecisionTree（Scikit-learn）
可解释性分析	SHAP（Shapley Additive exPlanations）

三、SQL 数据分析：价值分层流失洞察

3.1 数据预处理与类别映射

在进入分析前，首先对数据表字段进行规范化处理。原始数据中"是否已流失"字段以中文"是/否"存储，为便于聚合计算，通过 SQL 将其映射为数值型标签：

```
UPDATE `电子商务客户流失数据` SET `是否已流失` = 1 WHERE `是否已流失` = '是';
```

```
UPDATE `电子商务客户流失数据` SET `是否已流失` = 0 WHERE `是否已流失` = '否';
```

同时，依据客户终身价值（CLV，单位：美元）对客户进行价值分层，分层标准如下：

价值类别	客户终身价值（CLV）区间
高价值	10,000 美元以上
中价值	5,000 – 10,000 美元
低价值	1,000 – 5,000 美元
极低价值	1,000 美元以下

3.2 客户价值类别流失净值占比

利用 SQL 窗口函数与聚合函数，按客户价值类别统计用户总数、流失人数、流失率，并重点计算流失客户的潜在 CLV 损失及其占比。计算结果如下表：

客户类型	用户总数	流失人数	流失率(%)	流失损失 CLV（美元）	流失 CLV 占比(%)
高价值	40,063	16,580	41.38	521,008,054.87	96.01
中价值	5,002	2,067	41.32	16,339,579.49	3.01
低价值	3,980	1,629	40.93	5,114,038.83	0.94
极低价值	955	377	39.48	197,264.97	0.04

3.3 客户细分类别流失净值占比

进一步从客户细分（业务类型）维度进行同样的流失净值分析：

客户细分	用户总数	流失人数	流失率(%)	流失损失 CLV（美元）	流失 CLV 占比(%)
个人消费者	22,320	9,741	43.64	258,316,718.81	47.60
高端客户	12,565	4,838	38.50	127,185,734.73	23.44
小型企业	9,983	4,057	40.64	105,693,602.68	19.48
企业客户	5,132	2,017	39.30	51,462,881.94	9.48

3.4 核心发现：高价值客户流失损失占比 96%

这是本次 SQL 分析最关键的洞察。观察各价值层级的流失率可以发现，**高、中、低、极低四类客户的流失率都在 40% 上下，差距并不明显**——如果只看流失率，很容易得出"流失问题在各层级均匀分布"的误判。

然而，当引入"流失损失的潜在 CLV"这一价值视角后，真相浮出水面：**高价值客户流失所损失的潜在 CLV 占据了全部流失损失的 96.01%**。也就是说，每一个高价值客户的流失，其商业损失远超数十个低价值客户流失的总和。

这一发现直接决定了后续机器学习建模的策略方向：**模型不能仅仅追求"预测得准"，更要"重点预测得准"——必须让模型将注意力集中到高价值客户身上，优先、精准地识别高价值客户的流失风险。**

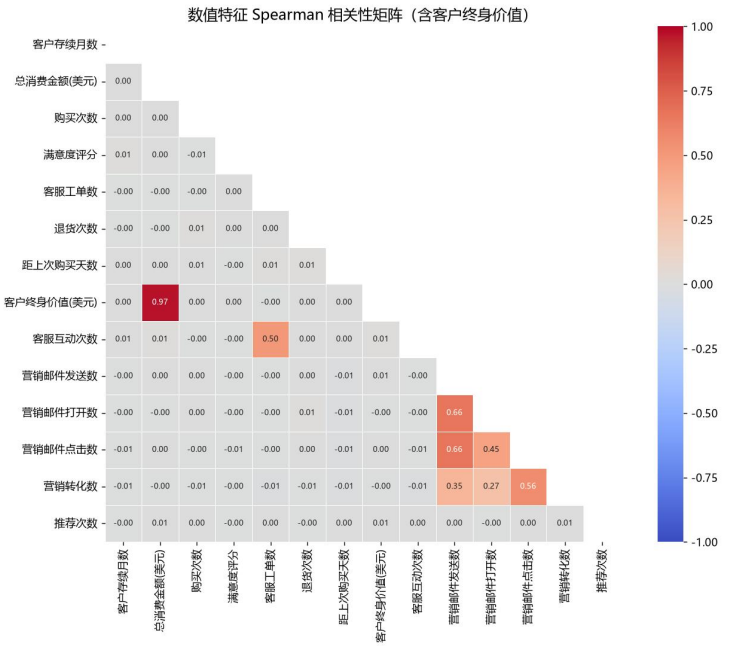
四、机器学习建模：流失概率预测

4.1 数据准备与特征工程

在 Python 端，首先将目标变量"是否已流失"转换为数值型标签，并从 35 个字段中筛选出 14 个数值型特征用于建模，包括：客户存续月数、总消费金额、购买次数、满意度评分、客服工单数、退货次数、距上次购买天数、客户终身价值、客服互动次数、营销邮件发送数、营销邮件打开数、营销邮件点击数、营销转化数、推荐次数。

4.2 特征相关性分析与降维

为避免特征之间的强共线性干扰模型，首先计算数值特征的 Spearman 秩相关系数（Spearman 对长尾分布更稳健），并绘制相关性热力图进行可视化诊断：



图：数值特征 Spearman 相关性矩阵（含客户终身价值）

从热力图可以清晰看到，**总消费金额(美元)与客户终身价值(美元)之间的相关系数高达 0.97**，属于典型的强共线性冗余特征。客户终身价值本身即由消费金额累积推导而来，两者信息高度重叠，若同时保留会稀释特征重要性、增加运算负担。

因此，在建模时**剔除客户终身价值(美元)这一高相关冗余特征**，最终保留 13 个特征进入模型。

4.3 样本不平衡与双重加权机制

第一重：类别不平衡处理。训练集中流失（正样本）16,576 条、留存（负样本）23,424 条，正负样本比例约为 1.41 ： 1。模型通过 scale_pos_weight 参数对少数类加权，缓解类别不平衡带来的预测偏向。

第二重：业务价值加权。单纯的数量平衡无法体现不同价值层级的差异。项目引入基于客户价值的自定义样本权重（sample_weight），对不同价值类别施加差异化惩罚：

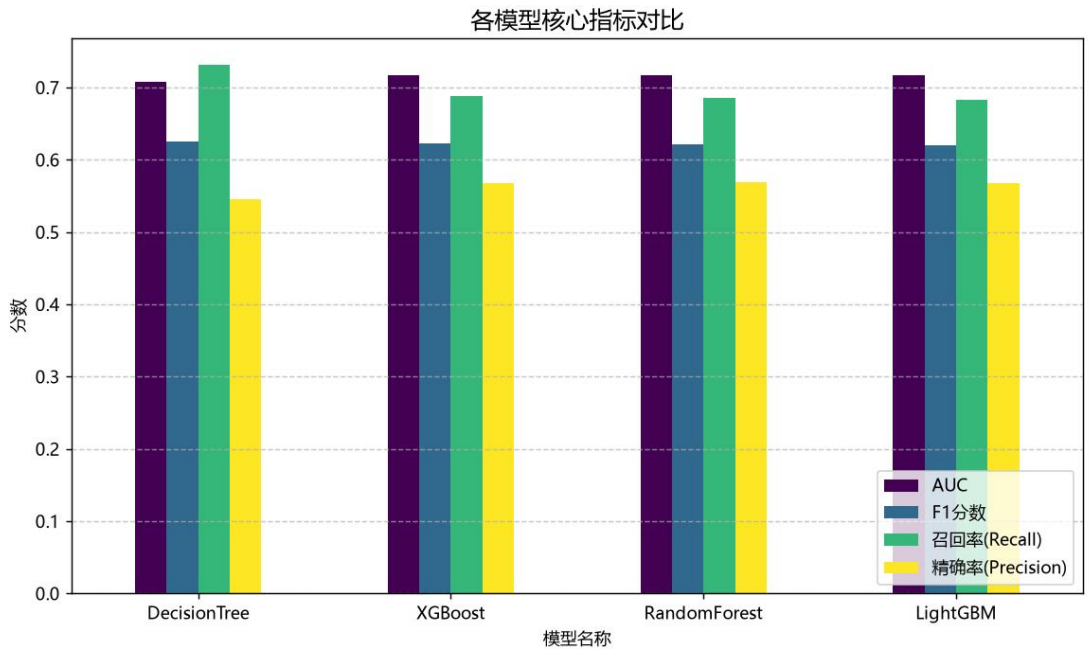
价值类别	样本权重
高价值	**10.0**
中价值	3.0
低价值	1.0
极低价值	0.5

高价值客户样本被赋予 10.0 的权重，是低价值客户的 10 倍。这意味着模型一旦错误地"放过"一个即将流失的高价值客户，其代价将被放大 10 倍。**这一机制强迫模型将注意力集中在高价值流失客户身上，实现"加大预测高价值错误的惩罚"这一业务目标。**

4.4 四模型基线对比

项目搭建了 LightGBM、XGBoost、RandomForest、DecisionTree 四种模型的"打擂台"评估框架，每个模型均通过 RandomizedSearchCV 随机搜索调参（3 折交叉验证、以 F1 分数为优化目标），并在测试集上统一输出五项指标：

模型名称	准确率 (Acc)	AUC	F1 分数	精确率	召回率
LightGBM	0.6588	**0.7174**	0.6201	0.5678	0.6831
XGBoost	0.6593	0.7171	0.6220	0.5679	0.6875
RandomForest	0.6602	0.7171	0.6217	0.5692	0.6848
DecisionTree	0.6419	0.7076	0.6248	0.5454	0.7312



图：各模型核心指标对比

从对比结果可得出两个结论：**其一，四个模型的整体效果十分接近**，AUC 均集中在 0.71 左右，F1 均在 0.62 左右，说明在给定特征与加权机制下模型能力已接近稳定上限；**其二，LightGBM 的 AUC 最高（0.7174）且 LightGBM 模型的综合稳定性最佳**。决策树虽召回率略高（0.7312），但准确率（0.6419）与精确率

（0.5454）明显偏低，泛化能力弱于集成模型。因此最终选定 **LightGBM** 作为冠军模型。

4.5 LightGBM 深度交叉验证

选定 LightGBM 后，随机搜索得到的最优参数组合为：num_leaves=31、learning_rate=0.05、n_estimators=100、min_child_samples=20、subsample=1.0、colsample_bytree=1.0、reg_alpha=0.1、reg_lambda=5。

为验证模型的泛化能力与稳定性，对冠军模型进行 5 折交叉验证：

指标	数值
平均测试集 AUC	0.7181
平均测试集 F1	0.6182
平均测试集 Acc	0.6566
平均训练集 AUC	0.7532
过拟合 Gap	0.0350

交叉验证的平均测试 AUC 为 0.7181，与训练集 AUC（0.7532）之间的过拟合差值（Gap）仅为 0.035，低于 0.05 的警戒线，**说明模型泛化良好、稳健可靠，未出现过拟合现象**。

4.6 测试集最终预测

将冠军模型在独立测试集（10,000 条样本）上进行最终预测，分类报告如下：

类别	精确率 (Precision)	召回率 (Recall)	F1 分数	样本数
留存（0）	0.75	0.64	0.69	5,923
流失（1）	0.57	**0.68**	0.62	4,077

最终模型在测试集上的 AUC 达到 0.7174，其中流失类（少数类）的**召回率**

达到 68%。这一指标对业务意义重大：召回率越高，越能"不漏掉"真正会流失的客户。相比盲目追求整体准确率，本项目更看重流失客户的召回能力，确保为业务端输出一份高召回率的高危客户干预名单。

五、模型可解释性分析

模型不仅要"预测得准"，还要"解释得清"。项目通过特征重要性排名与 SHAP 可解释性分析，回答"哪些因素在驱动客户流失"这一关键问题。

5.1 特征重要性排名

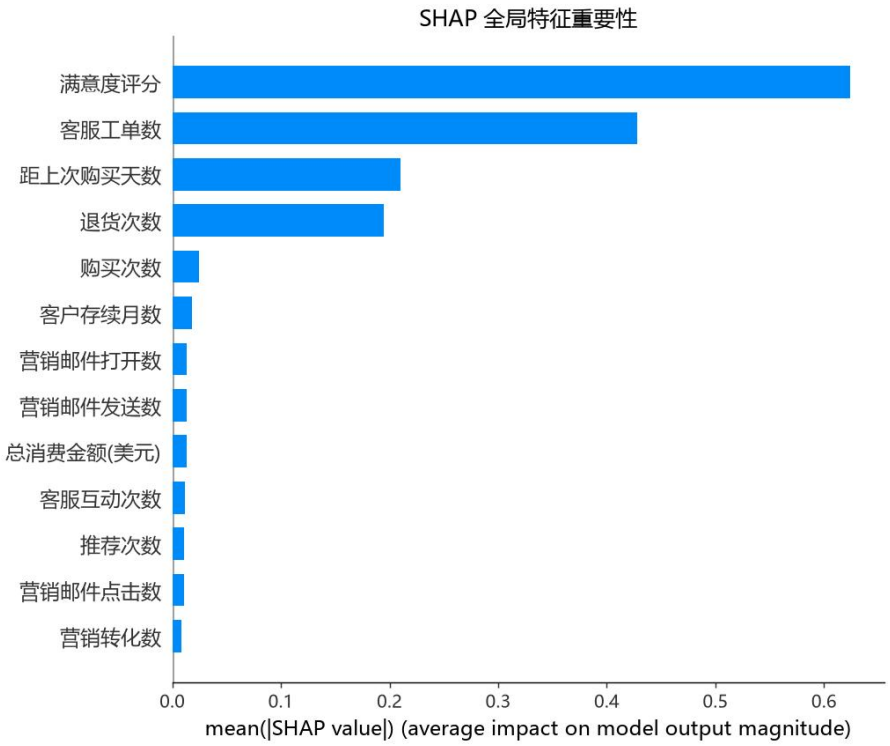
LightGBM 模型输出的特征重要性排名前十如下：

排名	特征	重要性
1	距上次购买天数	510
2	总消费金额(美元)	309
3	退货次数	297
4	客服工单数	276
5	客户存续月数	260
6	购买次数	227
7	营销邮件打开数	204
8	营销邮件发送数	200
9	营销邮件点击数	183
10	推荐次数	156

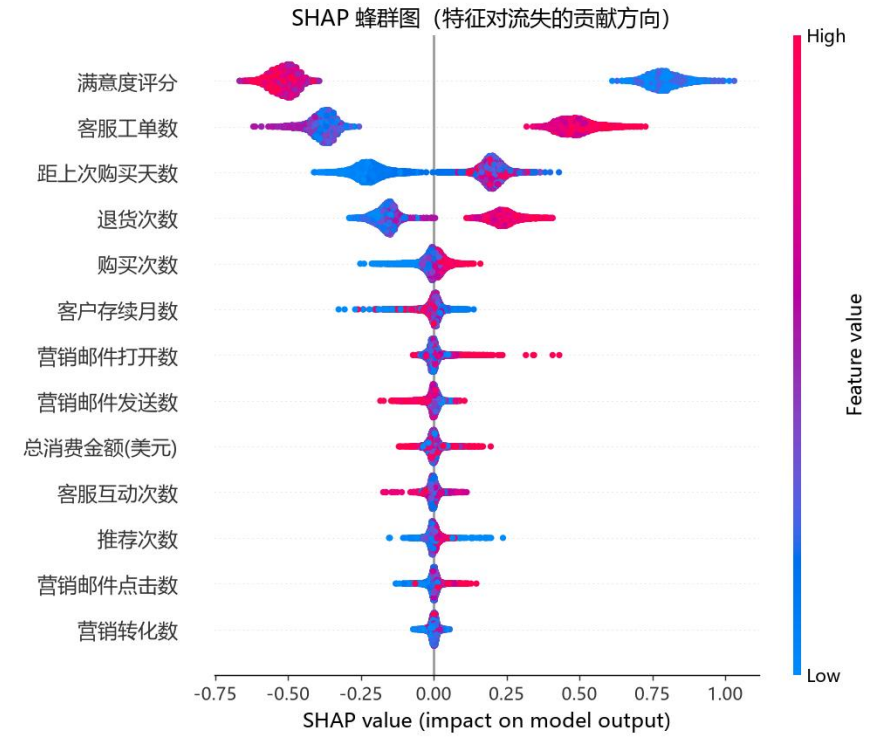
"距上次购买天数"以 510 的重要性高居榜首，说明客户距上次购买的时间间隔是预测流失最关键的信号——**越久没有复购的客户，流失风险越高**。

5.2 SHAP 解释

进一步通过 SHAP 分析，从全局视角解读各特征对流失预测的贡献方向：



图：SHAP 全局特征重要性



图：SHAP 蜂群图（红色代表特征值高、蓝色代表特征值低）

SHAP 蜂群图揭示了特征对流失的贡献方向：**"客服工单数"与"距上次购买天数"是导致流失的最核心因素**——客服工单数越高（服务问题越多）、距上次购买越久（活跃度下降），流失风险越高。结合单用户归因分析（Force Plot），业务团队能够直接向销售解释"为什么系统预测这个高价值客户会流失"，将黑盒预测转化为可理解、可行动的洞察。(虽然 SHAP 全局排名中“满意度评分”位列第一，但在实际业务归因时，我更倾向于向销售解释具有“直接干预价值”的具体行为特征，即通过解决工单和唤醒购买来解决根本的满意度问题)。结合单用户归因分析，我更能向业务团队解释“为什么系统预测这个高价值客户会流失”，将预测转化为可理解、可行动的洞察。

六、业务落地：风险分层与挽留策略

基于模型输出的全量流失概率，项目将每一位客户划分为三个风险等级：高危（流失概率 ≥ 0.5）、中危（0.3 ≤ 流失概率 < 0.5）、低危（流失概率 < 0.3）。

全量客户的风险分层分布如下：

风险等级	客户数	占比
高危	24187	48.4%
中危	15143	30.3%
低危	10670	21.3%

进一步交叉"价值类别 × 风险等级"：

客户价值类别	高危	中危	低危
高价值	**19392**	12104	8567
中价值	2455	1,498	1049
低价值	1899	1239	842

客户价值类别	高危	中危	低危
极低价值	441	302	212

模型最终输出了一份按流失概率降序排列的《全量客户流失预警名单》，其中预测流失概率最高的前几名客户均为高价值客户（预测概率高达 0.86）。基于这份名单，运营团队可以采取差异化挽留策略：**高危 + 高价值客户**投入最高优先级，进行 1v1 人工召回、专属客户经理跟进、个性化权益定制；**中危客户**通过定向优惠券、会员权益提醒等自动化营销手段激活；**低危客户**维持常规运营，无需过度投入营销资源。

通过这种"把资源集中在刀刃上"的精细化运营方式，可大幅提升营销 ROI，实现真正的降本增效。

七、总结

本项目完整构建了一套从"数据洞察"到"模型预测"再到"业务落地"的客户流失分析闭环：

SQL 洞察定方向——发现高价值客户流失损失占比高达 96%，明确挽留核心对象；**价值加权强模型**——创新性地将业务价值（CLV）融入样本权重，让模型聚焦高价值客户；**多模型对比选最优**——在四模型打擂台中选定综合表现最优、稳定性最佳的 LightGBM；**SHAP 解释可落地**——找到"客服工单数、距上次购买天数"等核心流失驱动因素；**风险分层促行动**——输出高危客户预警名单，支撑精细化挽留策略。